Clasificación de imágenes de Rayos X

PAKOTINAIKOS

ÍNDICE

1 Equipo de trabajo

2 Motivaciones y Contexto

3 Objetivos del proyecto

4 Diseño de la arquitectura

5 Depuración y limpieza del dataset

6 Preprocesamiento de archivos dicom

7 Aumento de datos

8 Split de datos: Conjuntos de Validación

9 Modelos utilizados durante la competición

10 Nuestra solución

11 Conclusiones

EQUIPO DE TRABAJO

Javier Ruiz

Antonio Faura

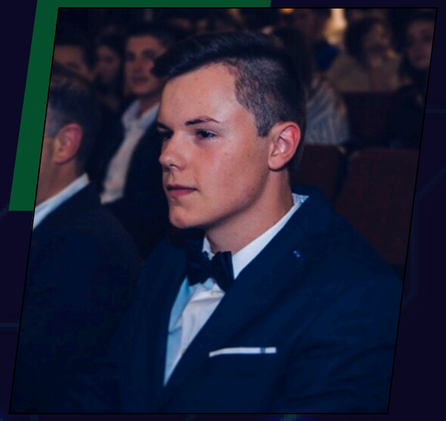

Miguel Herrero

MOTIVACIONES Y CONTEXTO

- Clasificación de imágenes de Rayos X
- Problema en el uso del filtrado de PACS
- Importancia de la correcta clasificación de partes del cuerpo a partir de rayos X

NUESTRO CONJUNTO DE DATOS

- Dataset de 1278 radiografías para train y 328 radiografías para test
- Formato DICOM
- SOPInstanceUID propio de cada imagen
- Columna target de 22 clases

Abdomen = 0
Tobillo = 1
Columna cervical = 2
Tórax = 3
Clavículas = 4
Codo = 5
Pies = 6
Dedos = 7
Antebrazo = 8
Mano = 9
Cadera = 10

Rodilla = 11
Pierna = 12
Columna lumbar = 13
Otros = 14
Pelvis = 15
Hombro = 16
Senos paranasales = 17
Cráneo = 18
Muslo = 19
Columna torácica = 20
Muñeca = 21

OBJETIVOS DEL PROYECTO

1. Garantizar que el mayor número posible de imágenes sea clasificado correctamente

   Métricas: Accuracy

2. Agilizar computacionalmente el proceso para conseguir mayor escalabilidad y adaptabilidad

   Métricas: Time (ms) per inference step (CPU,GPU)

3. Desarrollar un sistema que se pueda integrar fácilmente en los flujos de trabajo clínicos existentes, facilitando la adopción por parte de los profesionales de la salud

4. Proporcionar interpretaciones claras de las predicciones para los profesionales de la salud, destacando los casos con mayor incertidumbre para revisiones adicionales

DISEÑO DE LA ARQUITECTURA

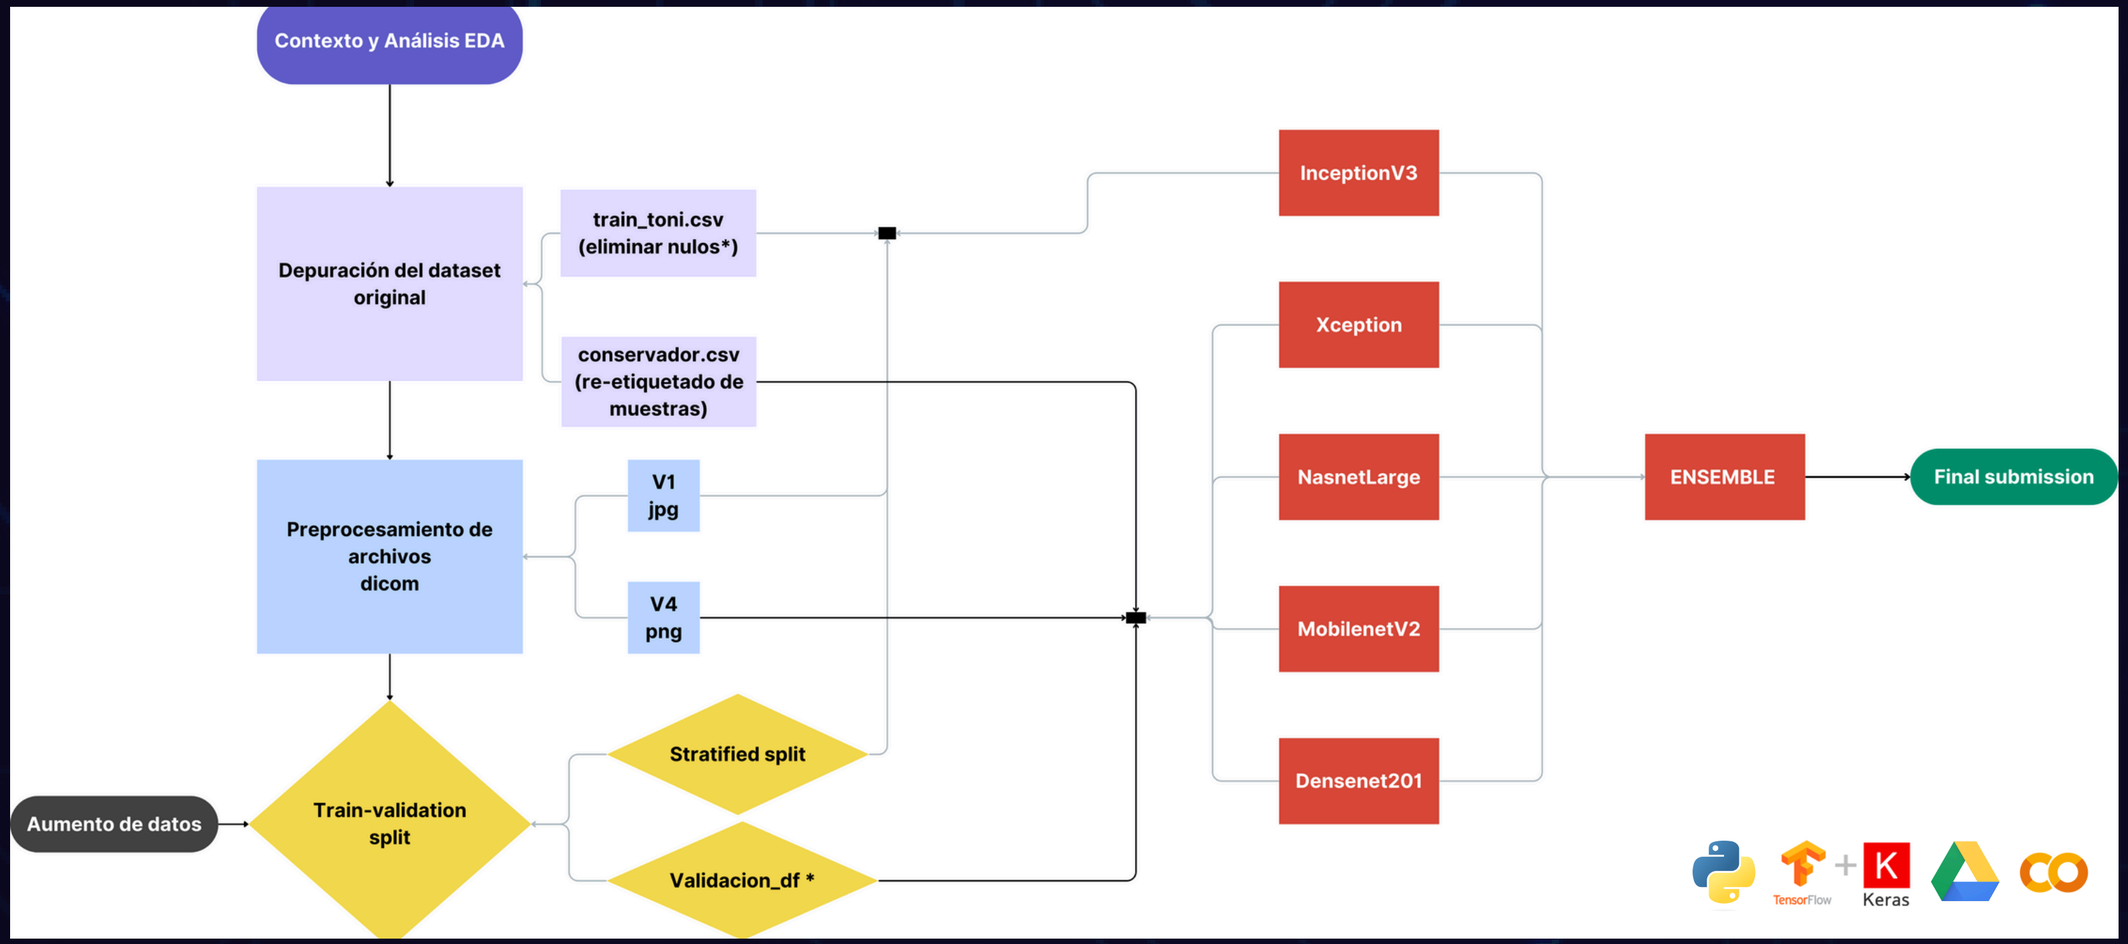

DEPURACIÓN Y LIMPIEZA DEL DATASET

train_toni

1278 ⟶ 1248 imágenes

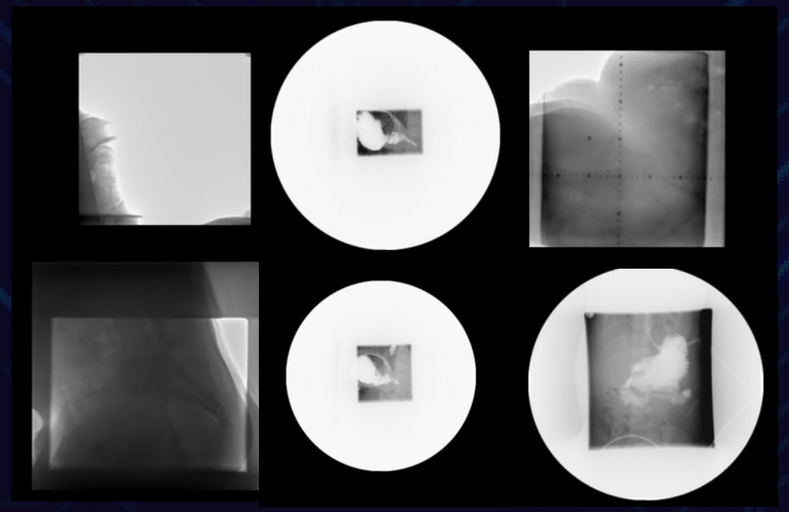

conservador

1278 imágenes

No es una rodilla

Target ‘11' ⟷ Target ‘6’

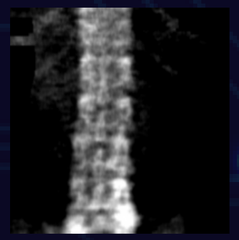

Es una densitometría

Target ‘13' ⟷ Target ‘14’

PREPROCESADO DE ARCHIVOS DICOM

V1

- 256,256
- JPG
- 8 bits
- ‘Monochrome2'
- Normalización 0,1

V4

- 256,256
- PNG
- 16 bits
- Padding negro
- Relación de aspecto original
- ‘Monochrome2'
- Normalización -1,1

AUMENTO DE DATOS

- Rotaciones en un rango de 0 a 20 grados.
- Rotaciones de 90 grados para agregar variedad en las orientaciones de las imágenes.
- Traslaciones horizontales para simular cambios de posición lateral en las imágenes.
- Traslaciones verticales para simular cambios de posición vertical en las imágenes.
- Recortes (shear_range) para aplicar distorsiones de cizallamiento a las imágenes y variar su forma.
- Zoom para simular cambios en la distancia focal de la cámara y acercamientos/alejamientos en las imágenes.

SPLIT DE DATOS: CONJUNTOS DE VALIDACIÓN

Stratified split

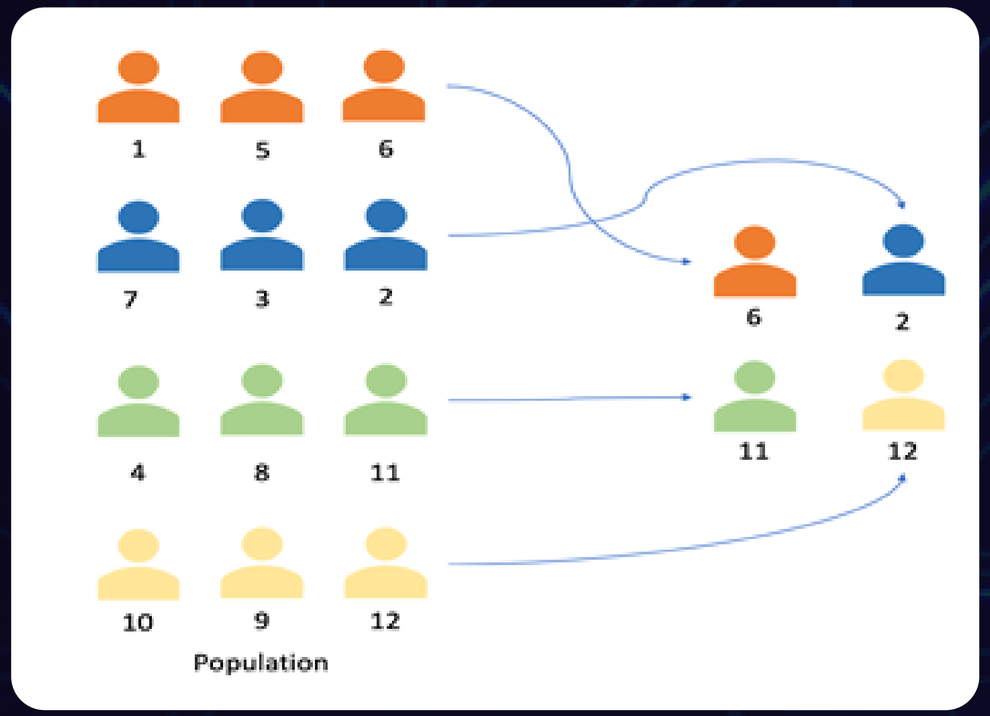

Validacion_df *

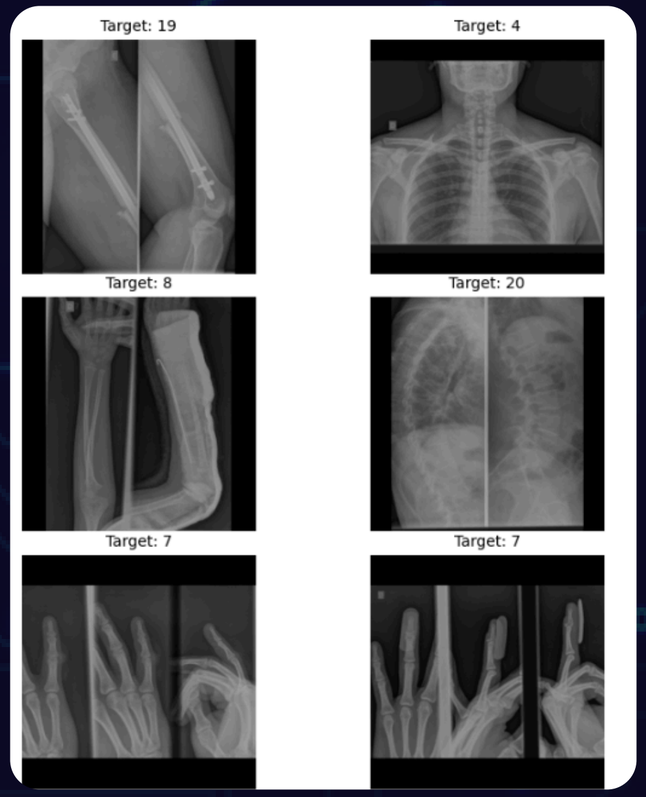

MODELOS UTILIZADOS DURANTE LA COMPETICIÓN

	Re-entreno	F1-Score
InceptionV3	✗	93.2 %
Xception	✓	92.9%
NasnetLarge	✓	88.9%
MobilenetV2	✓	94.2 %
Densenet201	✓	93.9 %

ENSAMBLE

F1-Score ENSAMBLE

95.4 %

NUESTRA SOLUCIÓN: MOBILENETV2

Desde *PAKOTINAIKOS* sabemos que el rendimiento es importante, y una precisión alta en nuestras predicciones es clave para que nuestro proyecto sea una solución. Sin embargo, maximizar el uso eficiente de los recursos computacionales es lo que puede llevarlo a ser una solución REAL.

Por ello, MobilenetV2 es una excelente opción para nuestra tarea dado que es uno de los modelos más rápidos y livianos del mercado, y hemos conseguido maximizar su rendimiento hasta un 94.2%.

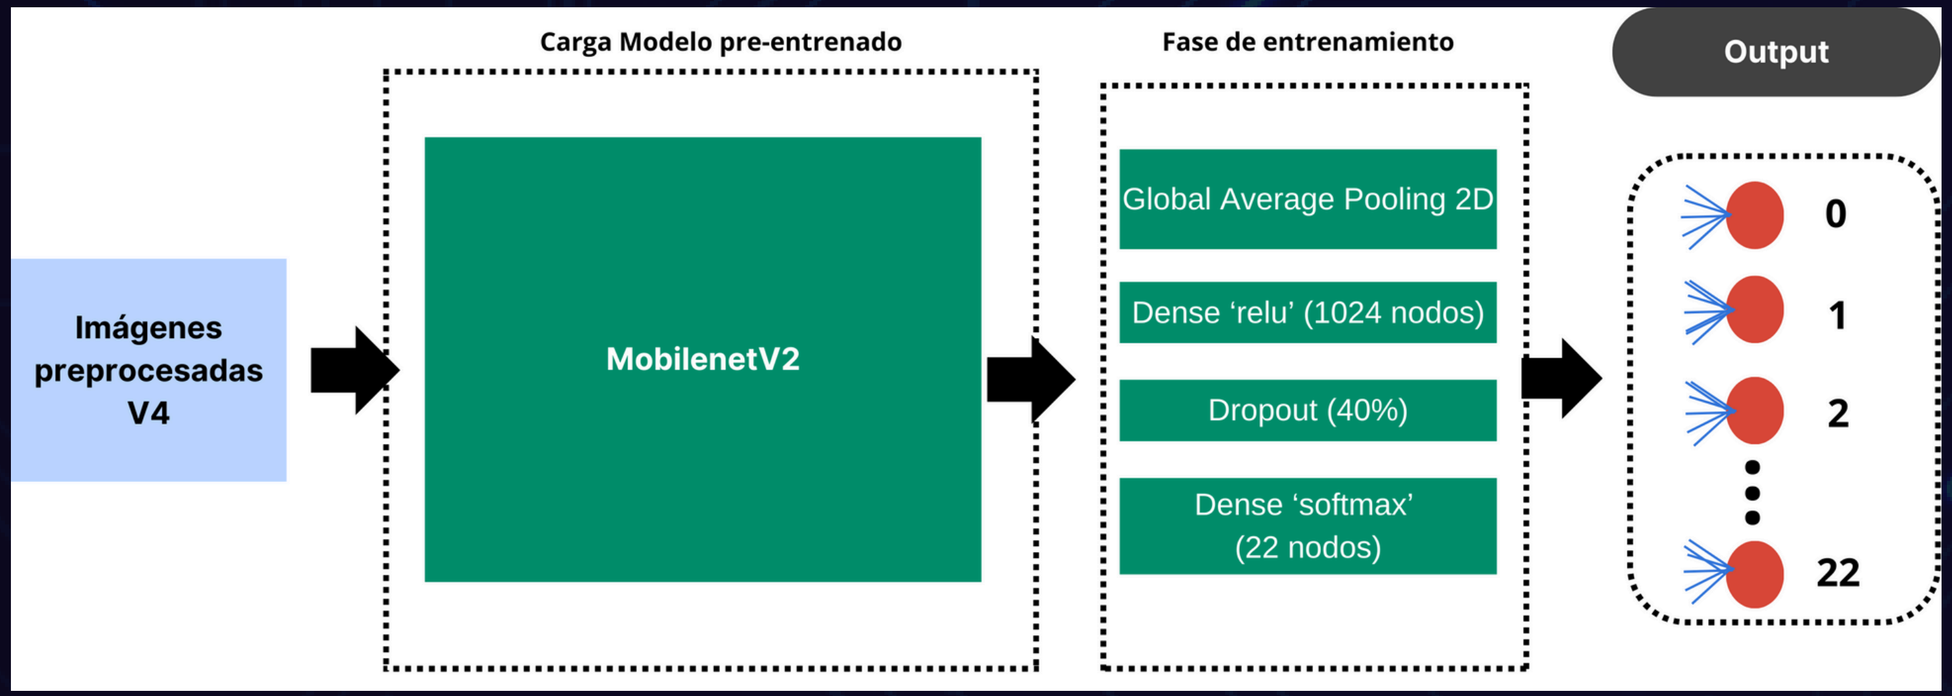

F1-Score: 94.2%

Características

- Tamaño: 14 MB
- Parámetros: 3.5 M
- Profundidad: 105 capas
- Inferencia(CPU): 25.9 ms
- Inferencia(GPU): 3.8 ms

CONCLUSIONES Y SIGUIENTES PASOS

- Nuestro modelo ha demostrado ser prometedor en la clasificación de partes del cuerpo en imágenes radiológicas, lo que sugiere su viabilidad para aplicaciones clínicas. Además, la liviandad y rapidez de nuestra red, permite que nuestro clasificador se pueda adaptar fácilmente a estructuras de aprendizaje automático más grandes como por ejemplo detectores de anomalías, sirviendo como filtrado de las fuentes de datos PACS.

- Creemos que una mejora futura podría venir de recolectar más datos radiológicos para corregir el desbalance actual del conjunto de datos y lograr una mayor generalización de nuestro modelo.

- Colaborar con profesionales de la salud también nos podría proporcionar retroalimentación y una mejora en la interpretación clínica del etiquetado de algunas imágenes de entrenamiento y en las predicciones.

¡GRACIAS POR VUESTRA ATENCIÓN!